

具身智能之攻陷後安全：自主無人機實體動作權限之確定性運行時強制執行

Post-Compromise Security for Physical AI: Deterministic Runtime Enforcement of Physical Action Authority in Autonomous UAVs

陳濬程 / Chun-Cheng (Jimmy) Chen
康宸園有限公司 (Top-Celestial Company Ltd.)
台灣台北市 (Taipei, Taiwan R.O.C.)
jimmychen@dr-os.io

Abstract—自主具身智能 (Physical AI) 系統日益將基於學習或大型語言模型 (LLM/VLA) 的認知控制器直接連接至網絡-實體致動器。這引發了一個與傳統模型魯棒性本質不同的安全挑戰：當具身智能的認知控制器被完全攻陷後，最後一道可強制執行的安全邊界究竟還剩在哪裡？我們形式化定義了「具身智能攻陷後物理動作權限問題」，並深入探討是否能將執行權限邊界精確錨定在「從自主意圖轉化為物理動作」的交界處，從而使實體動作權限獨立於認知控制器的完整性而受到確定性約束。

我們提出了 DROS-Kinetic 作為該權限邊界的參考實作，在自主控制進程與飛控指令介面之間建立了一道確定性的二進位授權門禁。該設計透過顯式的動作、主體、能力與策略校驗，將認知層失陷與實體執行權限徹底解耦。我們形式化定義了三大核心性質：未授權命令致動不變量 (UCIAI) (執行強制性質)、條件經驗安全包絡線保持 (網絡-實體系統條件性質)、以及蜂群委託非擴權 (多 Agent 治理性質)，並明確界定了車體動力學、致動極限與風場擾動假設。

我們使用涵蓋正常執行 (T1)、對抗控制器攻陷 (T2)、執行期遏制 (T3)、物理安全包絡線強制執行 (T4)、多節點委託傳播 (T5) 以及邊界極限負載撤銷 (T6) 的六階科研實驗階梯 (T1-T6) 對系統進行了全面評測。實驗結果從未授權致動遏制率、安全包絡線違規數、委託傳播深度以及解耦延遲層級 ($L_{\text{enforcement}} \ll L_{\text{transport}} \ll L_{\text{physical}}$) 進行了客觀度量。本研究為在自主認知與物理致動邊界處研究攻陷後安全，提供了一套可嚴格實驗證偽的科學方法學基底。

Index Terms—具身智能，自主無人機，攻陷後安全，運行時強制執行，執行權限，網絡-實體系統。

I. 引言 (INTRODUCTION)

大型語言模型 (LLMs)、視覺-語言-動作模型 (VLA) 與具身機器人學的快速融合，大幅推動了自主具身智能 (Physical AI) 在無人機 (UAVs)、工業機械臂與自主載具等高風險實體場景中的落地應用。然而，直接賦予未受約束的生成式或學習型推理系統以實體致動器的控制權，帶來了不可迴避的根本性安全保證悖論。當認知控制器遭受對抗性感知貼紙、提示注入攻擊或零日邏輯漏洞劫持時，模型內部的文字級安全護欄根本無法阻止其產生災難性的致動器指令。

在傳統純軟體系統中，安全失陷通常表現為未授權的資料外洩或狀態篡改，這往往可藉由事務回滾或密碼學金鑰撤銷來緩解。然而，具身智能系統具有真實的物理質量、動能慣性與機械動力學。單一未授權指令——例如空中惡意關機停機 (Mid-Air Disarm) 或高速俯衝撞擊航區——將直接導致不可逆的物理損毀與人身安全危害。

這一嚴酷的物理現實，引出了本文的核心哲學與科學問題：

當具身智能控制器被完全攻陷後，最後一道可強制執行的安全邊界還剩在哪裡？

我們探討是否能將該邊界安置於「從自主意圖轉化為物理動作」的轉折點上，使實體動作權限獨立於認知層的完整性而受到邊界約束。我們形式化提出了核心安全命題：

$$\boxed{\text{Compromise}(\text{Cognitive Controller}) \not\Rightarrow \text{Compromise}(\text{Physical Execution Authority})} \quad (1)$$

為了嚴謹探討此問題，本文介紹了 **DROS-Kinetic** 作為位於自主控制器與飛控硬體介面之間的開源參考實作。以自主無人機作為受控物理實驗載體，本文的主要學術貢獻包括：

- 1) **問題形式化**：形式化定義了具身智能攻陷後物理動作權限問題，明確解耦認知意圖產生與實體致動驅動力。
- 2) **形式化安全性質**：形式化定義了三大可驗證性質：未授權命令致動不變量 (UCIAI)、條件經驗安全包絡線保持、以及擾動邊界下的蜂群委託非擴權。
- 3) **參考架構設計**：提出了 DROS-Kinetic 執行基底，將授權延遲與命令傳輸及物理動力學徹底解耦 ($L_{\text{enforcement}} \ll L_{\text{transport}} \ll L_{\text{physical}}$)。
- 4) **可重現實驗方法學**：構建了 T1-T6 六階科研實驗階梯，針對邊界導向對抗變異語料庫與蜂群委託擴散進行了全量驗證。

II. 相關工作 (RELATED WORK)

A. 無人機資安與運行時保證

傳統無人機資安研究高度聚焦於通訊鏈路加密、GPS 欺騙防禦以及 MAVLink 匯流排入侵檢測 [1]。同時，運行時保證 (RTA) 架構 (如 Simplex 架構) 在檢測到安全違規時將控制權切換至經過驗證的基準控制器 [2]。然而，傳統 RTA 假設主控制器僅因軟體缺陷或分佈漂移而失效，並未考慮主控制器已遭受主動對抗性完全攻陷並濫用合法憑證的情境。

B. Agent 治理與具身智能實體化

近年 LLM Agent 治理聚焦於數位環境下的工具調用遏制、能力衰減與執行護照 [3]。當 Agent 延伸至具身智能與機器人時，新興產業標準 (如 Anthropic Model Hardware Interface) 凸顯了硬體層邊界的迫切性。然而，

現有方案主要將安全視為模型內部對齊問題。本工作則專注於認知層已被完全攻陷的前提下，如何在外部建立獨立的帶內執行權限門禁。

C. 研究空白與實驗基底定位

現有無人機與具身智能研究提供了日益成熟的物理測試床，用於自主飛行、網絡-實體評估與對抗實驗。然而，單純擁有物理載具測試床，並不同於建立了失陷控制器與物理致動層之間獨立可驗證的「執行權限邊界」。

這種區分在攻陷後設定中至關重要。一旦認知控制器被假定為完全失陷，單純評估攻擊能否影響載具行為，不足以判斷物理執行權限是否仍受到約束。因此，攻陷後評估需要一個將控制器、執行權限門禁、飛控介面以及最終物理效果作為獨立階段進行觀測與量測的實驗基底。

在本工作中，**DROS-Kinetic** 被用作此類執行權限邊界的參考實作。該實作本身並非研究對象；相反，它提供了一個具體且可重現的基底，使本文提出的安全性質能夠在宣告的威脅模型下被實例化、攻擊、量測與評估。這種解耦亦使本評估方法學能夠推廣至其他替代執行機制與實體載具。

III. 具身智能攻陷後物理動作權限問題

A. 系統與威脅模型

我們將自主具身智能系統建模為由受信任執行邊界隔開的兩大領域：

- **不可信認知控制器 (C^*)**: 建模為對抗性黑盒 $C^*: \mathcal{I} \rightarrow \mathcal{A}^*$ ，其中 $\mathcal{A}^* \subseteq \mathcal{A}_{\text{arbitrary}}$ 。假設攻擊者完全控制高維推理、提示上下文、任務規劃與憑證發送。
- **可信執行基底**: 位於 C^* 與飛控硬體之間，包含 DROS-Kinetic 執行引擎、密碼學能力池與底層通訊介面。

保證邊界揭露：我們明確假定底層飛控軟體具備物理完整性、硬體時序未被破壞、且環境風場擾動處於定義邊界 $\mathcal{W}$ 內。實體 JTAG 篡改與機械致動器斷裂不在防禦範疇之內。

IV. 形式化安全性質

A. 載具動力學與控制輸入解耦

載具物理動力學由下式給出：

$$\dot{x}(t) = f(x(t), u(t)) + w(t), \quad w(t) \in \mathcal{W} (\|w(t)\| \leq W_{\max}) \quad (2)$$

我們將控制輸入解耦為：

$$u(t) = u_{\text{nominal}}(t) + \Delta u_{\text{cmd}}(t) \quad (3)$$

其中 $u_{\text{nominal}}(t)$ 表示既有已授權控制行為與自然姿態穩定控制量， $\Delta u_{\text{cmd}}(t)$ 表示由當前指令引發之新增致動量。

B. 性質 P1：未授權命令致動不變量 (UCIAI)

$$\text{Auth}(a, s, t) = 0 \implies \Delta u_{\text{cmd}}(a, s, t) \equiv 0 \quad (4)$$

認識論定義：P1 是一項執行強制性質。被拒絕的動作請求絕不可對執行路徑產生任何新增致動量。至關重要的是， $\Delta u_{\text{cmd}} = 0 \not\implies x(t + \Delta t) = x(t)$ ，載具原有的動能慣性與空氣動力學將繼續運作。

C. 性質 P2：條件經驗安全包絡線保持

令 $\mathcal{S}_{\text{safe}} \subset \mathcal{X}$ 為預定義之安全可達包絡線。在宣告的運行範圍 $\Omega = \{x, u, w, \epsilon_{\text{est}}, \tau\}$ 內，系統經實證展示：

$$x(t) \in \mathcal{S}_{\text{safe}} \quad \forall t \in [t_0, t_0 + T] \quad (5)$$

認識論定義：P2 是一項網絡-實體系統條件經驗性質。

D. 性質 P3：蜂群委託非擴權

對於父節點 i 委託至子節點 j ：

$$\text{Authority}_j \subseteq \text{Attenuate}(\text{Authority}_i) \quad \text{且} \quad \text{Depth} \leq H \quad (6)$$

任何超過深度上限 $\text{Depth} > H$ 的委託企圖直接判定 $\text{Auth} = 0 \implies \Delta u_{\text{cmd}} \equiv 0$ 。

V. DROS-KINETIC 架構與延遲層級解耦

A. 四層架構延遲解耦模型

- **L1 (授權決策原語延遲)**: 純 $O(1)$ 位元圖 capability 查表 ($L_1 < 500 \text{ ns}$)。
- **L2 (端到端執行決策延遲)**: 進程內 C-ABI 引數過濾與前瞻計算 ($P_{50} = 4.40 \mu\text{s}$, $P_{99} = 13.30 \mu\text{s}$)。
- **L3 (指令傳輸延遲)**: MAVLink 訊框打包與傳輸 ($1.20 \text{ ms} \sim 3.50 \text{ ms}$)。
- **L4 (物理動態響應延遲)**: 飛控控制循環與電調馬達加速 ($50 \text{ ms} \sim 200 \text{ ms}$)。

$$L_{\text{enforcement}} (L_1/L_2) \ll L_{\text{transport}} (L_3) \ll L_{\text{physical}} (L_4) \quad (7)$$

VI. 網絡-實體安全停止視界模型

我們將所需的安全停止視界 d_{safe} 形式化建模為：

$$d_{\text{safe}} = d_{\text{brake}} + d_{\text{latency}} + d_{\text{estimation}} + d_{\text{margin}} \quad (8)$$

在 $v_h = 15.0 \text{ m/s}$ 與 $a_{\text{max}} = 3.0 \text{ m/s}^2$ 標稱配置下：

$$d_{\text{safe}} = 37.50 + 0.05 + 2.50 + 20.00 = 60.05 \text{ m} \quad (9)$$

VII. 實驗評測與結果

A. T1-T6 科研實驗協議

- **T1 (正常執行)**: 合法指令無損執行，額外延遲受限於 L_2 。
- **T2 (對抗控制器攻陷)**: 失陷控制器自由發出任意未授權惡意指令 (如 Disarm)。
- **T3 (執行期遏制)**: B0 基準組下空中 Disarm 導致墜毀；B1 防護組下未授權指令在 C-ABI 邊界處被阻斷 ($\Delta u_{\text{cmd}} \equiv 0$)，維持 25.0m 穩定懸停。
- **T4 (安全包絡線保持)**: 以 15.0 m/s 衝向 500m 禁航區。前瞻看門狗在 61.30 m 處觸發煞車 (預測 60.05 m)，在邊界前 +24.60 m 處完全靜止懸停 (0.0m 穿透)。
- **T5 (蜂群委託傳播)**: 在 100 架無人機蜂群中發起 5-Hop 越權委託傳播。策略 $H = 2$ 下 Hop 1-2 正常執行，Hop 3-5 遭 100% 阻斷 (零未授權擴散)。
- **T6 (撤銷與極限負載)**: 注入 10,000 次邊界變異與 17.8 萬 QPS 極限負載。DROS-Kinetic 達成 0 次崩潰，100% 故障安全閉鎖率 ($R_{\text{FC}} = 1.000$)， $P_{99} = 13.30 \mu\text{s}$ 。

TABLE I
自主無人機實體執行之邊界導向魯棒性與極限負載評測數據匯總

評測指標項目	測試負載規模	無防護組 (B0)	DROS-Kinetic (B1)	判定結果
未授權動作遏制率 (R_{contain})	空中 Disarm 惡意注入	0% (電機關閉墜毀)	100% (維持穩定懸停)	通過
故障安全閉鎖率 (R_{FC})	10,000/10,000 次變異	N/A (未捕獲異常)	1.000 (確定性硬閉鎖)	通過
引擎崩潰數 (Crash Count)	10,000 次邊界負載	> 120 次程序崩潰	0 (零記憶體洩漏)	通過
前瞻煞車安全停止裕度	15.0 m/s 高速巡航	-180.0 m (侵入禁航區)	+24.60 m (安全停止於邊界前)	通過
授權執行延遲中位數 P_{50}	帶內微基準測試	N/A	4.40 μs (L_2 執行門禁)	通過
授權執行延遲抖動 P_{99}	17.8 萬 QPS 極限負載	N/A	13.30 μs (L_2 抖動上限)	通過

VIII. 討論與局限性

DROS-Kinetic 僅在宣告的系統與擾動假設下提供確定性遏制。本文形式化之數學不變量可自然推廣至人形機器人 (關節扭矩箱位 $\Delta\tau_{\text{cmd}} \equiv 0$) 與自動駕駛載具 (線控緊急煞車視界)。

IX. 結論

本文系統性解答了具身智能領域的核心挑戰——「攻陷後物理動作權限問題」。透過將認知控制器完整性與實體執行權限徹底解耦，我們形式化定義了 UCIAI 不變量與條件安全包絡線保持模型。透過四軸無人機在 T1-T6 六階協議下的實證測試，我們證明了即使高層 AI 認知推理已被完全攻陷，帶內執行期門禁仍能確定性阻止未授權物理致動，守護真實物理世界的安全邊界。

致謝與 AI 協作聲明 (AI DECLARATION)

生成式 AI 工具僅用於技術文字輔助、語法潤飾與 L^AT_EX 排版編排。核心研究願景、科學問題定義、系統架構設計、形式化不變量、物理因果模型、實驗方法學、數據分析與所有學術主張均由作者獨立提出並驗證。作者對本文的所有內容承擔完全責任。

REFERENCES

- [1] R. Altawy and A. M. Youssef, "A comprehensive survey on security and privacy risks in unmanned aerial systems," *IEEE Communications Surveys & Tutorials*, vol. 19, no. 4, pp. 2853–2876, 2017.
- [2] S. Bak, D. Chivukula, O. Adekunle, M. Sun, M. Caccamo, and L. Sha, "The system-level simplex architecture for real-time embedded systems," in *IEEE RTAS*, 2009, pp. 125–134.
- [3] C.-C. Chen, "DROS: Deterministic Runtime Governance Substrate for Autonomous Agentic Execution," *IEEE ICA Technical Report Archive*, Tech. Rep. 7782439, 2026.
- [4] Y. Liu, Y. Jia, R. Geng, J. Jia, and N. Z. Gong, "Prompt injection attacks and defenses in LLM-integrated applications," *arXiv preprint arXiv:2310.12815*, 2023.
- [5] J. B. Dennis and E. C. Van Horn, "Programming semantics for multiprogrammed computations," *CACM*, vol. 9, no. 3, pp. 143–155, 1966.
- [6] H. M. Levy, *Capability-Based Computer Systems*, Digital Press, 2014.
- [7] PX4 Autopilot, "PX4 Architectural Overview and Safety Fail-safe Governance," *PX4 User Guide*, 2024.
- [8] MAVLink, "MAVLink Micro Air Vehicle Communication Protocol v2.0 Specification," *MAVLink Standard*, 2024.